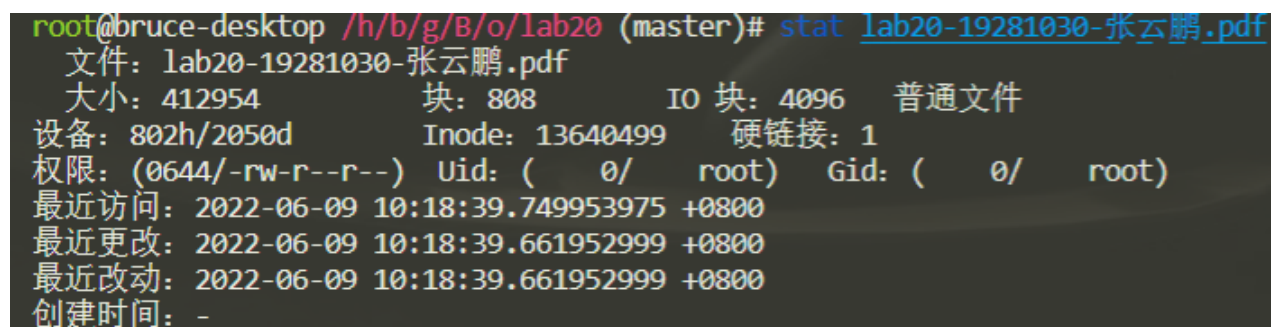


Linux 特定文件系统设计探析

19281030-张云鹏

实验截图



```
root@bruce-desktop /h/b/g/B/o/lab20 (master)# stat lab20-19281030-张云鹏.pdf
 文件: lab20-19281030-张云鹏.pdf
 大小: 412954          块: 808          IO 块: 4096   普通文件
设备: 802h/2050d      Inode: 13640499   硬链接: 1
权限: (0644/-rw-r--r--) Uid: (  0/   root)  Gid: (  0/   root)
最近访问: 2022-06-09 10:18:39.749953975 +0800
最近更改: 2022-06-09 10:18:39.661952999 +0800
最近改动: 2022-06-09 10:18:39.661952999 +0800
创建时间: -
```

实验环境

- Ubuntu20.04 LTS

Linux源码分析

内核源码下载

下载内核最新版本源码

The Linux Kernel Archives

[About](#)[Contact us](#)[FAQ](#)[Releases](#)[Signatures](#)[Site news](#)

Protocol	Location
HTTP	https://www.kernel.org/pub/
GIT	https://git.kernel.org/
RSYNC	rsync://rsync.kernel.org/pub/

Latest Release

5.18.3

mainline:	5.19-rc1	2022-06-06	[tarball]	[patch]	[view diff]	[browse]	
stable:	5.18.3	2022-06-09	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
stable:	5.17.14	2022-06-09	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
longterm:	5.15.46	2022-06-09	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
longterm:	5.10.121	2022-06-09	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
longterm:	5.4.197	2022-06-06	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
longterm:	4.19.246	2022-06-06	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
longterm:	4.14.282	2022-06-06	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
longterm:	4.9.317	2022-06-06	[tarball]	[pgp]	[patch]	[inc. patch]	[view diff] [browse] [changelog]
linux-next:	next-20220609	2022-06-09					[browse]

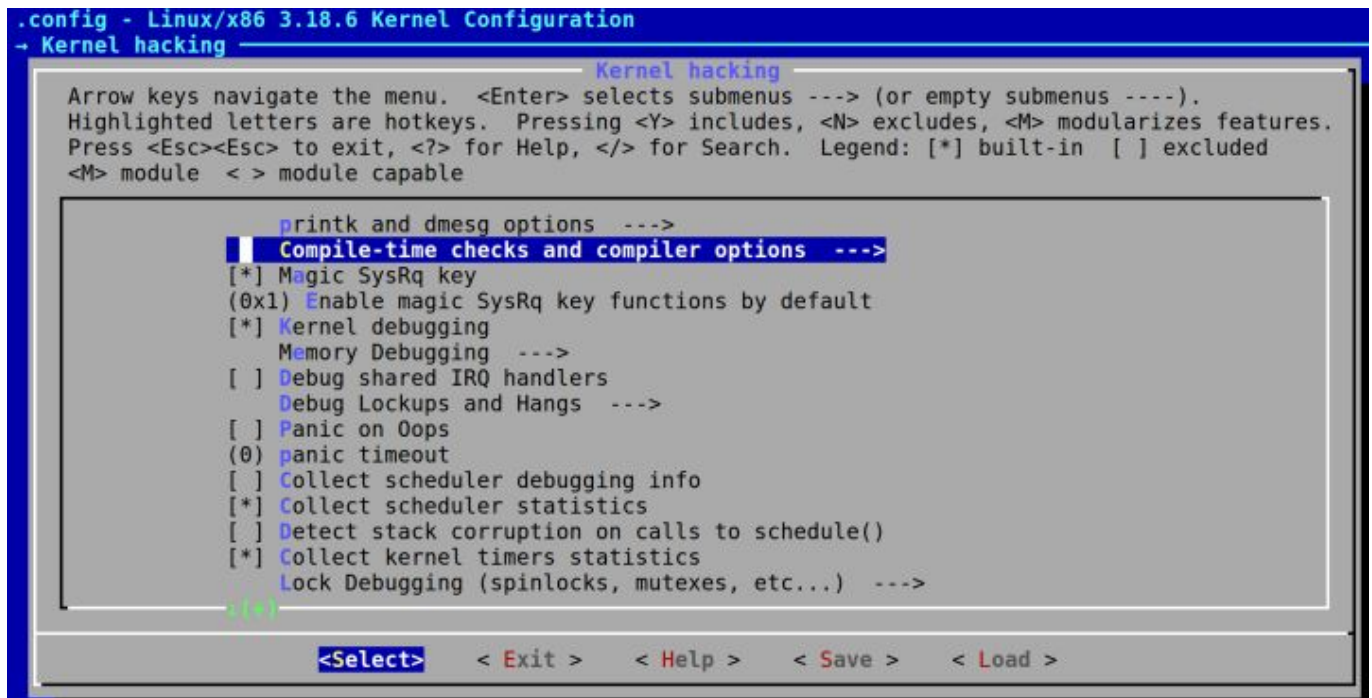
```
wget https://cdn.kernel.org/pub/linux/kernel/v5.x/linux-5.18.3.tar.xz
```

解压源码

```
xz -d linux-5.18.3.tar.xz
tar xvf linux-5.18.3.tar
```

编译源码

```
cd linux-5.18.3
make i386_defconfig
cd ~/19281030zyp/    $设置文件系统根目录
mkdir rootfs
cd menu
gcc -o init linktable.c menu.c test.c -m32 -static -lpthread
cd ../rootfs
cp ../menu/init ./
find . | cpio -o -H newc | gzip -9 > ../rootfs.img
```



源码分析

进程与文件系统

```

struct task_struct {
    .....
    /* filesystem information */
    struct fs_struct *fs;
    /* open file information */
    struct files_struct *files;
    /* namespaces */
    struct nsproxy *nsproxy;
    .....
}

```

- fs成员指向进程当前工作目录的文件系统信息。files成员指向了进程打开的文件的信息。nsproxy指向了进程所在的命名空间，其中包含了虚拟文件系统命名空间。
- fs中包含了文件系统的挂载点和挂载点的dentry信息。而files指向了一系列的struct file结构，其中struct path结构用于将struct file和vfsmount以及dentry联系起来。struct file保存了内核所看到的文件的特征信息，进程打开的文件列表就存放在task_struct->files->fd_array[]数组以及fdtable中。
- task_struct结构还存放了其打开文件的文件描述符fd的信息，这是用户进程需要用到的，用户进程在通过文件名打开一个文件后，文件名就没有用处了，之后的操作都是对文件描述符fd的，在内核中，fget_light()函数用于通过整数fd来查找对应的struct file对象。由于每个进程都维护了自己的fd列表，所以不同进程维护的fd的值可以重复，例如标准输入、标准输出和标准错误对应的fd分别为0、1、2
- struct file的mapping成员指向属于文件相关的inode实例的地址空间映射，通常它设置为inode->i_mapping。在读写一个文件时，每次都从物理设备上获取文件的话，速度会很慢，在内核中对每个文

件分配一个地址空间，实际上是这个文件的数据缓存区域，在读写文件时只是操作这块缓存，通过内核有相应的同步机制将脏的页写回物理设备。super_block中维护了一个脏的inode的链表。

```
struct file_operations {
    struct module *owner;
    loff_t (*llseek) (struct file *, loff_t, int);
    ssize_t (*read) (struct file *, char __user *, size_t, loff_t *);
    ssize_t (*write) (struct file *, const char __user *, size_t, loff_t *);
    ssize_t (*aio_read) (struct kiocb *, const struct iovec *, unsigned long,
loff_t);
    ssize_t (*aio_write) (struct kiocb *, const struct iovec *, unsigned long,
loff_t);
    int (*readdir) (struct file *, void *, filldir_t);
    unsigned int (*poll) (struct file *, struct poll_table_struct *);
    int (*ioctl) (struct inode *, struct file *, unsigned int, unsigned long);
    long (*unlocked_ioctl) (struct file *, unsigned int, unsigned long);
    long (*compat_ioctl) (struct file *, unsigned int, unsigned long);
    int (*mmap) (struct file *, struct vm_area_struct *);
    int (*open) (struct inode *, struct file *);
    int (*flush) (struct file *, fl_owner_t id);
    int (*release) (struct inode *, struct file *);
    int (*fsync) (struct file *, struct dentry *, int datasync);
    .....
};
```

文件系统打包

在制作好了文件系统的目录之后，可通过特定于文件系统类型的工具对目录进行打包，即制作文件系统。例如squashfs文件系统的打包工具为mksquashfs。除了打包之外，打包工具还针对特定文件系统生成超级块和inode节点信息，最终生成的文件系统镜像可以被内核解释并挂载。

VFS相关数据结构

```
struct inode {
    /* 全局的散列表 */
    struct hlist_node i_hash;
    /* 根据inode的状态可能处理不同的链表中 (inode_unused/inode_in_use/super_block->dirty) */
    struct list_head i_list;
    /* super_block->s_inodes链表的节点 */
    struct list_head i_sb_list;
    /* inode对应的dentry链表，可能多个dentry指向同一个文件 */
    struct list_head i_dentry;
    /* inode编号 */
    unsigned long i_ino;
    /* 访问该inode的进程数目 */
    atomic_t i_count;
    /* inode的硬链接数 */
    unsigned int i_nlink;
```

```

uid_t          i_uid;
gid_t          i_gid;
/* inode表示设备文件时的设备号 */
dev_t          i_rdev;
u64            i_version;
/* 文件的大小, 以字节为单位 */
loff_t         i_size;
#ifdef __NEED_I_SIZE_ORDERED
seqcount_t     i_size_seqcount;
#endif
/* 最后访问时间 */
struct timespec i_atime;
/* 最后修改inode数据的时间 */
struct timespec i_mtime;
/* 最后修改inode自身的时间 */
struct timespec i_ctime;
/* 以block为单位的inode的大小 */
blkcnt_t       i_blocks;
unsigned int    i_blkbits;
unsigned short  i_bytes;
/* 文件属性, 低12位为文件访问权限, 同chmod参数含义, 其余位为文件类型, 如普通文件、目
录、socket、设备文件等 */
umode_t        i_mode;
spinlock_t     i_lock; /* i_blocks, i_bytes, maybe i_size */
struct mutex    i_mutex;
struct rw_semaphore i_alloc_sem;
/* inode操作 */
const struct inode_operations *i_op;
/* file操作 */
const struct file_operations *i_fop;
/* inode所属的super_block */
struct super_block *i_sb;
struct file_lock *i_flock;
/* inode的地址空间映射 */
struct address_space *i_mapping;
struct address_space i_data;
#ifdef CONFIG_QUOTA
struct dquot     *i_dquot[MAXQUOTAS];
#endif
struct list_head i_devices; /* 若为设备文件的inode, 则为设备的打开文件列表节点
*/
union {
    struct pipe_inode_info *i_pipe;
    struct block_device *i_bdev; /* 若为块设备的inode, 则指向该设备实例 */
    struct cdev *i_cdev; /* 若为字符设备的inode, 则指向该设备实例 */
};
__u32            i_generation;
#ifdef CONFIG_FSNOTIFY
__u32            i_fsnotify_mask; /* all events this inode cares about */
struct hlist_head i_fsnotify_mark_entries; /* fsnotify mark entries */
#endif
#ifdef CONFIG_INOTIFY
struct list_head  inotify_watches; /* watches on this inode */
struct mutex      inotify_mutex; /* protects the watches list */

```

```

#endif
    unsigned long        i_state;
    unsigned long        dirtied_when; /* jiffies of first dirtying */
    unsigned int         i_flags; /* 文件打开标记, 如noatime */
    atomic_t             i_writecount;
#ifdef CONFIG_SECURITY
    void                 *i_security;
#endif
#ifdef CONFIG_FS_POSIX_ACL
    struct posix_acl      *i_acl;
    struct posix_acl      *i_default_acl;
#endif
    void                 *i_private; /* fs or device private pointer */
};

```

super_block

```

super_block {
    /* 全局链表元素 */
    struct list_head      s_list;
    /* 底层文件系统所在的设备 */
    dev_t                 s_dev;
    /* 文件系统中每一块的长度 */
    unsigned long         s_blocksize;
    /* 文件系统中每一块的长度 (以2为底的对数) */
    unsigned char          s_blocksize_bits;
    /* 是否需要向磁盘回写 */
    unsigned char          s_dirt;
    unsigned long long     s_maxbytes; /* Max file size */
    /* 文件系统类型 */
    struct file_system_type *s_type;
    /* 超级块操作方法 */
    const struct super_operations *s_op;
    struct dquot_operations *dq_op;
    struct quotactl_ops *s_qcop;
    const struct export_operations *s_export_op;
    unsigned long          s_flags;
    unsigned long          s_magic;
    /* 全局根目录的dentry */
    struct dentry          *s_root;
    struct rw_semaphore     s_umount;
    struct mutex            s_lock;
    int                    s_count;
    int                    s_need_sync;
    atomic_t               s_active;
#ifdef CONFIG_SECURITY
    void                   *s_security;
#endif
    struct xattr_handler    **s_xattr;
    /* 超级块管理的所有inode的链表 */
};

```

```

struct list_head s_inodes; /* all inodes */
/* 脏的inode的链表 */
struct list_head s_dirty; /* dirty inodes */
struct list_head s_io; /* parked for writeback */
struct list_head s_more_io; /* parked for more writeback */
struct hlist_head s_anon; /* anonymous dentries for (nfs) exporting */
/* file结构的链表, 该超级块上所有打开的文件 */
struct list_head s_files;
/* s_dentry_lru and s_nr_dentry_unused are protected by dcache_lock */
/* 不再使用的dentry的LRU链表 */
struct list_head s_dentry_lru; /* unused dentry lru */
int s_nr_dentry_unused; /* # of dentry on lru */
struct block_device *s_bdev;
struct mtd_info *s_mtd;
/* 相同文件系统类型的超级块链表的节点 */
struct list_head s_instances;
struct quota_info s_dquot; /* Diskquota specific options */
int s_frozen;
wait_queue_head_t s_wait_unfrozen;
char s_id[32]; /* Informational name */
void *s_fs_info; /* Filesystem private info */
fmode_t s_mode;
/*
 * The next field is for VFS *only*. No filesystems have any business
 * even looking at it. You had been warned.
 */
struct mutex s_vfs_rename_mutex; /* Kludge */
/* Granularity of c/m/atime in ns.
 * Cannot be worse than a second */
u32 s_time_gran;
/*
 * Filesystem subtype. If non-empty the filesystem type field
 * in /proc/mounts will be "type.subtype"
 */
char *s_subtype;
/*
 * Saved mount options for lazy filesystems using
 * generic_show_options()
 */
char *s_options;
};
dentry:
struct dentry {
    atomic_t d_count;
    unsigned int d_flags; /* protected by d_lock */
    spinlock_t d_lock; /* per dentry lock */
    /* 该dentry是否是一个装载点 */
    int d_mounted;
    /* 文件所属的inode */
    struct inode *d_inode;
    /*
     * The next three fields are touched by __d_lookup. Place them here so they
     all fit in a cache line.
     */

```



```

/* 全局的dentry散列表 */
struct hlist_node d_hash; /* lookup hash list */
/* 父目录的dentry */
struct dentry *d_parent; /* parent directory */
/* 文件的名称, 例如对/tmp/a.sh, 文件名即为a.sh */
struct qstr d_name;
/* 脏的dentry链表的节点 */
struct list_head d_lru; /* LRU list */
/*
 * d_child and d_rcu can share memory
 */
union {
    struct list_head d_child; /* child of parent list */
    struct rcu_head d_rcu;
} d_u;
/* 该dentry子目录中的dentry的节点链表 */
struct list_head d_subdirs; /* our children */
/* 硬链接使用几个不同名称表示同一个文件时, 用于连接各个dentry */
struct list_head d_alias; /* inode alias list */
unsigned long d_time; /* used by d_revalidate */
const struct dentry_operations *d_op;
/* 所属的super_block */
struct super_block *d_sb; /* The root of the dentry tree */
void *d_fsdata; /* fs-specific data */
/* 如果文件名由少量字符组成, 在保存在这里, 加速访问 */
unsigned char d_iname[DNAME_INLINE_LEN_MIN]; /* small names */
};

```

文件系统测试与验证

测试命令

```
stat lab20-19281030-张云鹏.pdf
```

```

root@bruce-desktop /h/b/g/B/o/lab20 (master)# stat lab20-19281030-张云鹏.pdf
 文件: lab20-19281030-张云鹏.pdf
 大小: 412954      块: 808      IO 块: 4096   普通文件
设备: 802h/2050d   Inode: 13640499 硬链接: 1
权限: (0644/-rw-r--r--) Uid: (  0/   root)  Gid: (  0/   root)
最近访问: 2022-06-09 10:18:39.749953975 +0800
最近更改: 2022-06-09 10:18:39.661952999 +0800
最近改动: 2022-06-09 10:18:39.661952999 +0800
创建时间: -

```